

В ходе выполнения лабораторной работы был проведён комплексный анализ и оптимизация пайплайна инференса нейронной сети. Начальный этап включал настройку окружения и оценку аппаратных возможностей (NVIDIA GPU с 8 ГБ VRAM). Для задачи классификации CIFAR-10 с использованием аугментаций Albumentations достигнута точность $\geq 87\%$ за 10 эпох.

Ключевым этапом стало сравнение архитектур EfficientNet: переход с B3 на B0 показал потерю точности всего 2-3% при увеличении скорости обработки на 40%. Это подтверждает эффективность B0 для продакшн-сценариев, где важны и скорость, и качество.

Значительное ускорение достигнуто за счёт оптимизаций форматов моделей. Экспорт в ONNX сократил latency с 15 мс до 8 мс. Дальнейшее применение TensorRT дало дополнительный прирост throughput в 2 раза по сравнению с базовым ONNX.

Эксперимент с INT8-квантованием выявил оптимальный баланс: потери точности составили лишь 2.87% (с 85.63% до 83.17%), при этом скорость инференса возросла в 1.5 раза, а размер модели уменьшился на 60%. Это делает INT8 предпочтительным выбором для развёртывания на edge-устройствах.

Итог: комбинированное использование EfficientNet-B0, ONNX формата, TensorRT и INT8-квантования позволяет достичь 3-кратного ускорения инференса при минимальных потерях точности, что оптимально для промышленного применения.